面向知乎 QAWEB 的网络爬虫设计与实现

游浩然 黎张帆 郭金城

u201515429 u201514574 u201511174 @hust.edu.cn

January 2, 2018

Table of Contents

I. Introduction

II. Method

III. Experiment

项目描述

- 爬虫控制端:启动爬虫,停止爬虫,监视爬虫的运行情况
- 爬虫运行模块:包含三个小模块, URL 管理器、网页下载器、网页解析器
 - URL 管理器:对需要爬取的 URL 和已经爬取过的 URL 进行管理,可以从其中取出待爬取的 URL 传递给网页下载器。
 - 网页下载器:网页下载器将 URL 指定的网页下载下来,存储成一个字符串,传递给网页解析器。
 - 网页解析器:网页解析器解析传递的字符串,解析器不仅可以解析出需要爬取的数据,而且还可以解析出每一个网页指向其他网页的 URL,这些 URL 被解析出来会补充进URL 管理器。
- 数据输出模块:存储爬取的数据

开发平台

- 硬件平台: 个人 PC , 可连接 WEB 网络
- 软件环境:
 - 操作系统: WINDOWS 10 & Ubuntu
 - IDE: PyCharm Community Edition 2017.2.3
 - Python 版本: Python 3.6.3 |Anaconda, Inc.| (default, Oct 15 2017, 03:27:45)
- 项目所需库
 - Wxpthon: Python GUI 库
 - Selenium: Python 模拟浏览器操作库
 - Phantom:基于 selenium 的 Python 工业化模拟浏览器操作库,需设置运行路径或将 bin 文件夹放入系统路径中。

任务分工

| 姓名 | 负责模块 | 主要任务 |
|-----|--------|---------------------------------|
| 黎张帆 | 爬虫控制器 | 启动、停止、监视爬虫的运行情况;实现多线程爬取。GUI设计 |
| 游浩然 | 爬虫运行模块 | 知乎登陆; URL 管理器、网页下载器、网页解析器; 动态加载 |
| 郭金城 | 数据输出模块 | 通过网页标签抓取问题 URL 下的相关信息;动态加载 |

Table of Contents

I. Introduction

II. Method

- 整体框架设计
- 爬虫控制模块
- 爬虫运行模块
- 数据输出模块

III. Experiment

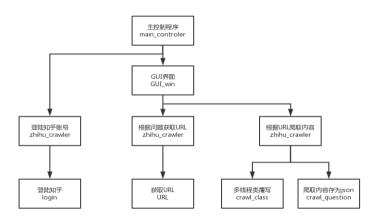


Figure 1: 整体框架设计

GUI 使用说明

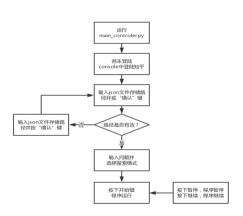


Figure 2: GUI 使用说明



Figure 3: GUI 界面

GUI 设计

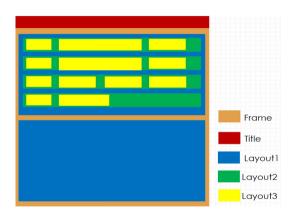


Figure 4: GUI 设计框图



Figure 5: GUI 界面

主程序流程

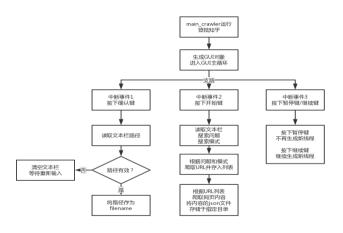


Figure 6: 主程序流程图

多线程控制

Thread 子类 Crawler

| Class Crawler | | |
|------------------------------------|--|--|
| Parent: threading.Thread | | |
| Method: | | |
| init(self, funcName, args=)#覆写父类方法 | | |
| run(self)#覆写父类方法 | | |
| _run(self) | | |

11 / 24

多线程控制

```
def run(self):
    try:
        self. run()
    except Exception as e:
        self.exitcode = 1
        self.exception = e
        self.exc_traceback = ''.join(traceback.format exception(*sys.exc info()))
        print("URL Crawler Exception: ", self.args[0])
        print(" self.exc traceback")
def run(self):
    try:
        self.funcName(self.args[0],self.args[1])
    except Exception as e:
        raise e
```

Figure 8: 覆写 run 方法

爬虫运行模块

本模块主要实现了爬虫的基本运行,分为两个主要部分:

- 知乎登陆
- 建立问题 URL 库
 - 针对具体问题 (Question) 搜索知乎的"综合"模块
 - 针对具体话题 (Topic) 搜索知乎的"话题"模块

其中对问题(Question)的爬取采用 PhantomJS 库来实现动态加载,对话题(Topic)的爬取采用模拟翻页来实现动态加载。

爬虫运行框图

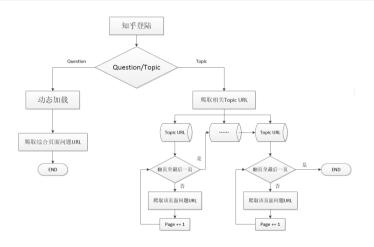


Figure 9: 爬虫运行框图

知乎登陆

使用手机的代理(User-Agent)来模拟登陆

Figure 10: headers 头文件信息

知乎登陆

采用验证码方式登陆,测试结果如下:

```
1 C:\Users\dell-pc\Anaconda3\python.exe C:\Users\dell-pc\Desktop\zhihu_crawler_py3\login.py
```

Figure 11: login

² Cookie cannot be load!

³ your name: None

⁴ please input your account:*****

⁵ please input your secret:*****

⁶ please input the captcha:f8dk

⁷ the status code returned by server: 200

^{8 {&#}x27;r': 0, 'msg': '登录成功'}

⁹ your name: 游浩然

网页下载和解析

网页下载函数即为下代码所示,使用 requests 库来抓取指定 URL 的内容:

```
1 def getHTMLText(url):
2     try:
3     r = requests.get(url, headers=headers)
4     # r.status_code 200
5     # r.encoding 'utf-8'
6     return r.content
7     except:
8     return "Error"
```

Figure 12: 网页下载

网页下载和解析

网页解析函数即为下代码所示,使用 BeautifulSoup 库来抓取解析网页:

```
1 demo = demo_temp.pop()
2 soup = BeautifulSoup(demo, 'html.parser')
3 for meta in soup.find_all('meta', attrs={'itemprop': 'url'}):
4 url_temp = meta.get('content')
5 url_list.append(url_temp)
```

Figure 13: 网页解析

URL 爬取和管理

- 对知乎"综合"模块进行爬取
- 对知乎"话题"模块进行爬取

存储为 urllist[] 列表格式供数据爬取模块调用

Question 页面动态加载

- 问题的完整描述需要执行点击操作,使用 selenium 模拟
- 通过鼠标的下滑不断地动态加载,使用 selenium 模拟

Question 页面动态加载

```
1 # 点击操作
2 try:
      click_btn = driver.find_element_by_xpath('//button[@class="Button QuestionRichText-more Button-plain"]')
 3
      ActionChains(driver).click(click_btn).perform()
      time.sleep(0.5)
      html\_text = driver.page\_source
7 except:
      html_text = driver.page_source
9 # 下滑操作
10 while(True):
      driver.execute_script('window.scrollTo(0,document.body.scrollHeight)')
11
12
      time.sleep(0.8)
13
      if(html text == driver.page source):
14
         break
15
      html text = driver.page source
```

Figure 14: selenium 模拟点击与下滑

Question 数据存储

效果展示

```
"吕学平"。"answer votes":"6"。"answer text":"文学的意义在于"记录"和"表达"AI的记录功能不用怀疑,健健的信息检索与汇总能力是远远在
"Karl Ernst"。"answer votes": "27"。"answer text": "我知道AI權文学创作肯定是有可能的。但是,我想说的不是这个问题,也不是这个"抵着
                        "answer_text": "<img src=\"https://pic2.zhimg.com/50/v2-ca629e3baa8a45f800c24f7a65c39e76
"Farhi Al", "answer votes": "28", "answer text": "AI的最后一个障碍只会是自批编译")
 "要验"、"answer votes":"314"、"answer text"、"谢谢。比据下期期,互作者的生活变量大多,无法预报,费雷兹是上多的个错头,今晚更成功
"李怡"、"answer votes":"4"、"answer text":"我觉得单纯从文学水平上去脚AI文学毫无意义,颇算AI将来第一字不差写出一个能得诺贝尔的文:
"Strius"、"answer votes": "17"、"answer text": "结论: 几乎不能创作结核的AT文章, 不是扣踢的原因, 是人的原因。先看着文学是怎么事的
"五百击"、"answer votes":"101"、"answer text":"AL早就开始文学创作,而且还美点获起了2016年"星新一文学奖"(以日本著名科幻小说家》
 "理想的酵菜"、"answer votes":"45"、"answer text":"别的我不知道现代语音流指不住而且不是在来来靠现在已经被干掉了甚至都没有使用at
 图图 " "Basser votes" "25" "Answer boy!" "在2014年到一下的严思图用相关的问题。基本上没有认为ATOU\法规图以简单大正的。而现在
于汗汗"、"answer votes": "9"、"answer text": "文学也分严肃文学和通常文学、那些编布图上的更文甚至是畅销一时的通俗小说。有朝一日at
  '当家的"、"answer votes":"64"、"answer text":"网尔法。先生,我在这里。我是不是要死了?我很请铺,是的,先生。我死之前可不可以非
"文艺苑花摇作死君"。"answer votes":"9"。"answer text":"ai可能永远槽不慢文学,但当ai成为主油以后,文学可能能没有存在的价值了")
     "answer votes": "4", "answer text": "不能。因为图灵判断。一个AI写出的文字,不需要报就人类才能生存,只要大爱读起来餐识不到!
"M3小锥结", "answer_votes": "9", "answer_text": "<img src=\"https://pic4.zhimg.com/50/v2-cf6d5054c234c428c75d39bb780cde2e
"王安治", "answer votes"; "31", "answer text"; "<ime data_rayheight=\"222\" src=\"https://pic3.zhing.com/59/y2-348h256
"稻草人","answer_votes":"1","answer_text":"回答这个问题前,必须先回答另一个问题:意识的是一种功能吗?这里的功能指的是物质的某种
"华钒迎恩","answer_votes":"7","answer_text":"文学不只由读者组成。写作的愉悦也是文学的一部分。")
"喆喆喆喆"。"answer votes":"4"。"answer text":"以现代人的阅读习惯,说不定这一块会比你想象的更快过克。这里有一位著名作家问答了,我就
"Grotrupida", "answer votes": "4", "answer text": "静於小冰尸经开放写诗了")
imowesome", "answer_votes"; "3", "answer_text"; "https://arxiv.org/pdf/1795.08897.pdf;;就文章里作者调查了AI研究者对未来AI取代
'AARD', "answer votes": "3", "answer text": "济值村东头se—除於江东子&lt:img src=\"https://pic1.zhimg.com/59/y2-fcf96b4a113g
"黑黑大树小树" "answer votes": "3" "answer text": "不是还有意乐、绘画、雕刻篆艺术另外、我国对有人说艺术要的就是人创造出来的东西
"匿名用户", "answer votes"; "4", "answer text"; "基础学科研究才是")
匿名用户"。"answer votes":"2"。"answer text":"还记得《锦绣未典》(原名《应女有春》)是如何成书的吗?而形还不是AI,不过是区区对
"苏轼若"。"answer votes":"2"。"answer text":"以艺术文学家的智商,他不是早就被AI爆了十条街。至于应用文学家(哲学家,科学家),早就的
     "answer_votes": "1", "answer_text": "你们平时看到的部分新闻福已经是AI自动编写自动发表的了。平时有感觉到吗?国内外很多媒体都
"匿名用户"、"answer votes":"1"、"answer text":"最后一个阵地。。。把基础科学研究的期2")
"匿名用户","answer_votes":"1","answer_text":"人类写作的意义应该不只在于吸引别人来看,还可以自我愉悦,AI应该不能时常翻出自己从存
"如果"、"answer votes":"1"、"answer text":"81.这问题把文学和大工智能联合在一起了,文学是经久不容的,大工智能又是时代的宏儿,挺有
"辣鸡翔","answer_votes":"1","answer_text":"简软小冰不是出了一部诗篇叫Alt;img_src-\ "https://pic2.zhimg_com/58/v2-1232de7828
```

Figure 15: json 效果展示

Question 数据存储

```
「"question_followers": "15,436"。
"question_title": "加賀田辺 村庁今帝用 AI 敵 UI?"。
"answer_number": "16 (2006)。
"question_text": "26 (2006)。
"question_text": "26 (2006)。
"question_text": "26 (2006)。
"question_text": "26 (2006)。
"question_text": "15 等用色"。
"prover_number": "1989,872"。
"question_text": "21378938"

}
```

Figure 16: json 效果展示

```
{
····"answer_votes": "0",
····"answer_author": "mac mico",
····"answer_text": "工欲善其事必先利其器,效率一定是首要的。UI设计之效率为王 - 设计与开发之效率 - 知乎专栏",
···"answer_id": 61575458,
···"answer_comment": "添加评论"
}
```

Figure 17: json 效果展示

Table of Contents

I. Introduction

II. Method

III. Experiment

• Thank You.